

Notes de Cours INF 3610

Olivier Sirois

2018-10-10

Contents

1	Cours 1,2 - Introduction	2
1.1	Systeme temps réelle	2
1.2	Systeme embarquée	3
1.2.1	contraintes	3
1.3	Class d'application	3
1.4	Noyau RTOS	4
1.4.1	Système avant/arrière-plan vs système multitache	4
1.4.2	Systeme multi-tache	4

Chapter 1

Cours 1,2 - Introduction

Quelques définitions:

1.1 Systeme temps réelle

Contraintes de temps très importantes, elle fait normalement partie des spécifications et doivent absolument être respecté. Normalement on parle d'un environnement qui agit sur des capteurs (senseurs) avec le système qui agit de façon correcte à ces stimuli dans un temps donné.

Les systèmes temps réelle sont normalement composé de deux sous-systèmes:

- contrôleur (PC ou microContrôleur)
- contrôlé (environnement physique)

La relation entre les deux sous-système est décrite par trois opérations

- échantillonnage
- calcule
- réponse

On différencie aussi entre les contraintes dure et les contraintes douces. Normalement, il est critique de devoir respecté les contraintes dure tandis que pour les contraintes c'est un peu plus flexible.

def des slides Un système qui doit répondre à un stimulus provenant d'un environnement dans un temps donné.

1.2 Systeme embarquée

Un système embarqué est un système autonome, souvent temps réelle, servant à résoudre des fonctions et des tâches spécifiques et disposant de ressources limitées. c'est limité parce que normalement on essaie de réduire les coûts parce qu'on veut en faire une production industrielle.

La complexité peut varier, c'est pas la même chose entre un lave-vaisselle et un contrôleur de missile. Normalement, on utilise du matériel pour la performance et la consommation tandis qu'on utilise du logiciel pour la flexibilité.

1.2.1 contraintes

Normalement, les métriques de conception d'un système embarqué sont :

- Taille
- fiabilité
- Consommation et dissipation de puissance
- coût de production
- temps de commercialisation (time to market)

On peut aussi avoir d'autres contraintes, genre:

- Tolérance aux pannes
- Résistance aux chocs et temp.
- BIST - built in self test. Pouvoir se diagnostiquer automatiquement
- Flexibilité et mise-à jour

Normalement, les systèmes embarqués sont utilisés dans un environnement réactif ou dans des situations très demandantes.

1.3 Class d'application

- **Systèmes dominés par le contrôle - contrôle sophistiqué** - Requiert des contraintes de temps, de temps dur (critical failure) et même plusieurs tâches simultanées (multitâche, concurrence, changement de contexte rapide requis μs).

Normalement, il y a peu de données associées à chaque machine à états. On peut normalement associer la mémoire sur puces à ces machines pour

accélérer le changement de contexte.

Un RTOS préemptif est généralement requis, c-a-d. un OS qui a un ordonnancement de tâche sophistiqué qui tâche les plus prioritaire en premier. Plusieurs algorithmes d'ordonnancement existe pour ces OS

- **Systèmes dominés par les données - contrôle qui traite une quantité importante de données.** - À certaine caractéristique:
 - Beaucoup de MIPS ou de MFLOPS
 - bande passante élevé
 - instruction spécialisé pour DSP
 - Support limité pour les interruptions et les changements de contexte
 - beaucoup de données pour un même contexte
 - très peu de changement de contexte son nécessaire car un seul flot de données mais à grand débit

1.4 Noyau RTOS

1.4.1 Système avant/arrière-plan vs système multitache

Arrière plan

s'applique normalement à des système peu complexe ou de petites tailles. C'est généralement une boucle infini qui appel à tour de rôle différent modules. La gestion des événements est généralement asynchrones (ISR). On peut avoir des interruptions de minuteur ou par I/O. On retrouve normalement cette méthode dans les systèmes de petite tailles (petit processeur). Cette approche est simple, mais elle très peu modulaire.

1.4.2 Systeme multi-tache

S'applique généralement a des systeme plus complexes. Elle favorise la réutilisation du code de par sa modularité. On donne accès à des outils évolués (Flgas, mutex, sémaphore, MB, Q). sa permet d'augmenter l'abstraction lors de la conception et exploite le concept de tâche et de programmation concurrente. (linux kernel).

Contrairement au systèmes types arriere/avant-plan, ces systèmes sont super modulaires. Un des désavantages est que sa prend un système massif/complexé et beaucoup de temps de développement. C'est très gourmand en mémoire alors sa peut être à reconsidérer dépendamment de ton hardware.

a. Noyau multitâche préemptif

Système avant/arrière plan:

Real-Time Kernels / Copyright 2001, Jean J. I.




Figure 1.1: Système avant-arrière plan

a. Noyau multitâche préemptif

Système multitâche:

Real-Time Kernels / Copyright 2001, Jean J. Labrosse




Figure 1.2: Système multitâche

tâche Un simple programme évoluant comme si il avait le CPU pour lui-même. Typiquement une boucle infini dans un des états suivant:...

Noyau préemptif

un système préemptif est un système ou les tâches peuvent utiliser des fonctions non réentrantes (excepté pour la synchronisation avec les ISR)

la latence d'interruption est relativement faible. Sa exploite moins les mutex et les sémaphores. Par contre ça l'a le désavantage d'être relativement moins

performant.

En générale, les système préemptif ne sont pas utilisé dans les systèmes embarqués.

Le paradigme est privilégié. Normalement sont des systèmes super réactif ou les tâches prioritaire s'exécutent en premier.

Noyau non préemptif (système multitâche coopératif) :

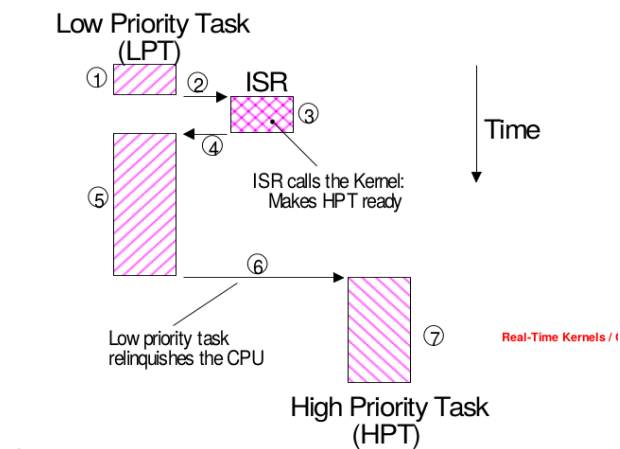


Figure 1.3: Exemple d'un noyau non-Preemptif

Priorité

Détermine l'exécution des tâches. c'est une métrique caractérisant son importance. Les tâches prioritaire vont être exécuter avant ceux moins prioritaire. Normalement on représente son importance avec un numéro, ce numéro peut être assigner au lancement de la tâche mais peut aussi être changer durant son exécution.

Programmation concurrente

Normalement utilisé pour exprimer le potentiel parallélisme et pour gérer les problème de synchronisation et de communication dans les systèmes multi-tâches.

Noyau préemptif :

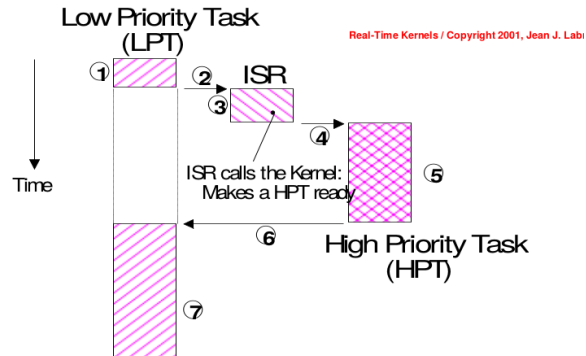


Figure 1.4: Exemple d'un noyau Preemptif

Ressources partagées

Techniquement, une ressource partagée est une ressource utilisée par plus d'une tâche, simultanément ou non.

La programmation concurrente introduit nécessairement le problème de partage des ressources. Une ressource est une entité exploitée par une tâche. Elle peut être corrompue si elle est simultanément utilisée, ce qui va inévitablement crasher..

Pour partager les ressources, on cherche nécessairement à avoir une fonction réentrante, une fonction qui peut être appelée par plus d'une tâche sans crainte de corrompre les données (threadsafe).

Pour s'assurer qu'une fonction soit réentrante, on s'assure généralement que les variables sont le plus souvent locales que possible.

On exploite les mutex/sémaphores lors de partage de variables.

Désactiver les interruptions ou le scheduler.. (pas recommandé).

Afin d'éviter la corruption de données, nous utilisons des fonctions **réentrantes** pour régler le problème. L'approche recommandée est d'utiliser des sémaphore/mutex

Sections critiques Une section est dite critique si elle doit être exécutée sans être interrompue. Ce qui pourrait causer un deadlock.. ou un traitement de données incorrect.

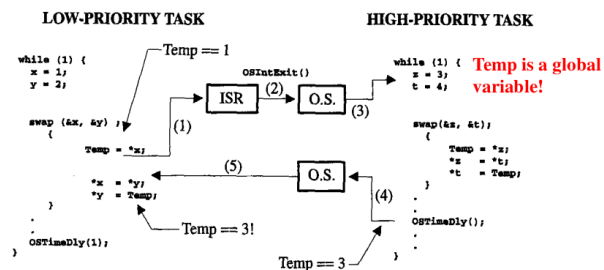


Figure 1.5: Fonction non reentrante

Sémaphores

Concept utilisé pour le partage de ressources. Lorsque plusieurs devices veulent accéder à la même mémoire, il faut utiliser un 'lock' pour s'assurer que les tâches ne modifient pas la mémoire en même temps. Ce cas pourrait en fait compromettre la cohérence de la mémoire et potentiellement amener une défaillance dans un système.

La communication et l'échange de données entre deux tâches peut être réalisé au moyen de ressources partagées. Plusieurs mécanismes peuvent assurer l'accès exclusif à une ressource partagée:

- Désactiver les interruptions (nono)
 - Approprié pour partager une variable entre une tâche et un ISR
 - " entre deux ISR
 - désavantage d'affecter la latence, ce qui n'est généralement pas permis dans les RTOS
- Désactiver le planificateur (scheduler)
 - inefficace pour partager des variables entre tâche/ISR
 - normalement pas utilisé
- test and set
 - Consiste à tester si une variable est égale à 0, et affecter la variable à 1.
 - Désavantage de garder la tâche dans une boucle infinie d'attente avant d'entamer la section critique (spinlock)
- Sémaphore
 - sa permet de:

Un sémaphore peut servir à contrôler l'accès à une ressource partagée (exclusion mutuel, aka mutex), signaler l'occurrence d'un événement ou de permettre à deux tâches de synchroniser leurs activités. On peut faire trois opérations sur un sémaphore:

- Initialize
- Wait
- Signal

c. Sémaphores

Exemple d'accès à une ressource partagée via l'obtention d'un sémaphore




Figure 1.6: Exemple d'un utilisation de Sémaphore pour le partage d'un ressource sensible

Deadlock Il se peut que l'utilisation de sémaphore introduise des effets indésirabl.

Deadlock:

Il se peut que l'utilisation de sémaphores (ou mutex) introduise des effets indésirables: l'inter-blocage (*deadlock*)!




Figure 1.7: Exemple d'un deadlock

Dans l'éventualité où deux tâches veulent avoir un mutex détenus par une autre tâches, les deux tâches vont attendre éternellement. il convient alors aux tâches :

- Acquérir toutes les ressources avant de procéder
- Acquérir les ressources dans le même ordre
- Relâcher les ressources dans le même ordre

Les sémaphores peuvent aussi être utilisés pour synchroniser des tâches. On appelle ça un rendez-vous unilatéral/bilatéral. uni/bi pour le nombre de tâches à synchroniser.

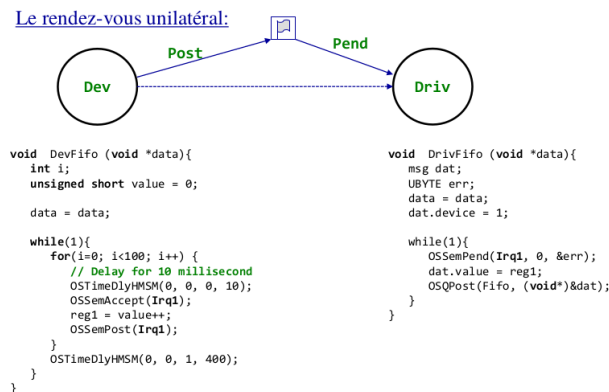


Figure 1.8: Exemple d'un rendez-vous unilateral

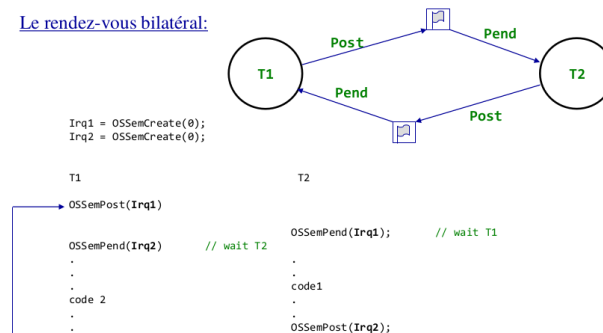


Figure 1.9: Exemple d'un rendez-vous bilateral

On peut aussi utiliser les sémaphores à fin de synchroniser plusieurs tâches. Nous allons tout simplement avoir une registre qui contient plusieurs bit ou chaque bit représente l'état d'un sémaphore. On utilise un ou logique pour procéder. Dans ce cas, on peut même les appeler des flags.

La communication entre plusieurs tâches se fait via des variables partagées. Les OS offre normalement des fonctionnalités de 'mailbox' ou de 'queues' INSÉRÉ SLIDE 68

Gestion des interruptions

l'interruption est un mécanisme matériel utilisé pour informer le processeur qu'un événement asynchrone a lieu.

les interruptions peuvent être synchrone (logiciel) ou asynchrone (externes). Les interruptions peuvent être activer ou désactiver.

Des interruptions externe permet à un processeur de traiter les événement lorsqu'ils surviennent plutôt que de poller continuellement sa venue (une boucle while)

synchrone = de l'intérieur du processeur ; asynchrone = à l'extérieur du processeur

Évidemment, les interruptions peuvent être imbriqués

Normalement nous allons avoir un compteur d'imbrications.

En traitant une interruption, nous devons inévitablement changer de contexte. Pour faire cela, le processeur sauvegarde la valeur de toutes les registres (stack) et retourne à cet état après avoir traité l'interruption.

Le choix de la tâche à traiter dépend de la nature préemptive du noyau. Dans un système préemptif, on fait en sorte qu'en sortant d'une interruption on n'est pas nécessairement obligé de retourner à la tâche qu'on exécutait avant de passer à l'ISR.

Problème d'inversion de priorité

Dans le cas où la tâche moins prioritaire bloque la tâche prioritaire en raison du manque de ressources/sémaphores, on inverse les priorités entre les tâches pour pouvoir libérer les ressources.

Normalement, la tâche prioritaire aurait dû s'exécuter en premier sauf que la tâche T4 avait un lock sur le mutex de la ressource Q. Pour régler le problème, on utilise **héritage de priorité** pour pouvoir régler le problème. Pour faire cela, on change la priorité entre T1 et T4 temporairement pour que T4 relâche les ressources nécessaires pour ensuite rechanger les priorités

e. Problème d'inversion de priorité

Le schéma suivant montre l'ordre d'exécution des tâches




Figure 1.10: Exemple du problème typique de scheduling

e. Problème d'inversion de priorité

Ce schéma provient de <http://www.cs.york.ac.uk/rtts/andy/RTS.html>

Héritage de priorité

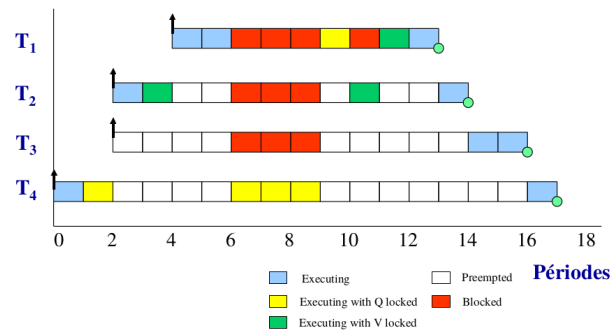


Figure 1.11: Exemple de l'héritage des priorités

au final, après l'héritage de priorité, T1 s'exécute en 9 périodes vs 12.

d'autres méthodes peuvent aussi être utilisées. Comme par exemple l'ICPP:

l'ICPP:

- minimise le temps de blocage
- demande peu de changements de contexte
- évite les problèmes d'inter-blocage (deadlock)




Figure 1.12: Exemple de le l'ordonnancement fait par une heuristique d'ICPP