

INF8225

Leçon 2

Christopher Pal
École Polytechnique de Montréal

Au menu

- Éléments de base de la probabilité et la conception d'un modèle probabiliste
- Les réseaux de Bayes
- Raisonnement incertain avec des réseaux de Bayes
- Les graphes de facteurs et les calculs probabilistes -> l'inférence probabiliste utilisant ces graphes

Dans notre plan du cours

- Notez que : on doit remettre le TP1 en utilisant moodle avant le labo de 31 janv.

| Période | Date | Activité | Salle |
|---------|------------|------------------|--------|
| 1 | 17 janvier | Énoncé du TP1 | L-3714 |
| 2 | 31 janvier | Énoncé du TP2 | L-3714 |
| 3 | 14 février | Énoncé du TP3 | L-3714 |
| 4 | 28 février | Énoncé du projet | L-3714 |
| 5 | 21 mars | Projet volet 1 | L-3714 |
| 6 | 4 avril | Projet volet 2 | L-3714 |

Les axiomes des probabilités

1. Toutes les probabilités sont comprises entre 0 et 1 pour toute proposition a , $0 \leq P(a) \leq 1$
2. Propositions nécessairement vraies: $P(\text{vrai}) = 1$
Propositions nécessairement fausses: $P(\text{faux}) = 0$
3. La probabilité d'une disjonction:
$$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$$

Notation: $P(a \wedge b) = P(a, b)$

Pourquoi probabilité?

- Bruno de Finetti 1931: Si l'agent A exprime une série de degrés de croyance qui violent les axiomes de la théorie des probabilités et si il y a une manière de parier sur les résultats, alors il y a une combinaison de paris par l'agent B, qui garantissent que l'agent A va perdre de l'argent à chaque fois.

Limites de la logique classique

- Fastidieux d'énumérer toutes les possibilités
- On n'a pas toute l'information
 - Sur la théorie de manière générale
 - Sur un cas particulier
- Solution: probabilités

Exemple de base de règles

DentisteCompétent \wedge Carie \Rightarrow DétecteAnomalie

Carie \Rightarrow Douleur

Que peut-on déduire à partir de cette base?

Exemple: Traduction en Prolog

```
detecteAnomalie(X,Y):-  
    dentisteComp(Y),  
    carie(X).
```

```
douleur(C) :-  
    carie(X).
```

```
dentisteComp(jean).  
douleur(moi).
```

- Quels types de requêtes sommes-nous vraiment souhaitant à poser?

Exemples:

- Si je vais chez le dentiste à Montréal, quelle est la probabilité qu'il détecte une anomalie
- Si je vais chez un dentiste sans douleur, quelle est la probabilité, qu'il va dire que j'ai une carie:

Probabilités – notions de base

- ***Variables aléatoires:*** chaque variable a un domaine de valeurs possibles (discrète, continue, binaire)
- ***Événement atomique:*** spécification complète d'un état du monde, qui se résume à une assignation de toutes les variables qui définissent ce monde
- Les événements atomiques sont mutuellement exclusifs
- L'ensemble de tous les événements atomiques est exhaustif

Probabilités – notions de base

- *Probabilité inconditionnelle*: degré de croyance en une proposition a , en l'absence de toute autre information
- *Probabilité conditionnelle*: $P(a|b)$ signifie la probabilité de a étant donné que tout ce que nous savons sur le monde est b
- $$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$

Notation

- La distribution conjointe est la probabilité d'une conjonction d'affectations particulières à chaque variable comme:

$$P(V_1 = v_1, V_2 = v_2, \dots, V_n = v_n)$$

- Souvent nous employons la notation:

a) $P(V_1, V_2, \dots, V_n)$ et b) $P(v_1, v_2, \dots, v_n)$

avec les variables discrètes ou binaires pour indiquer : a) les tables de probabilités (multidimensionnel) et/ou b) la probabilité unique associée à une configuration particulière

Les concepts essentiels de base

- **Règle du produit**
(Règle fondamentale)

$$P(A, B) = P(A | B)P(B)$$

- **Règle de Bayes**

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

- **Règle de la somme**
(Marginalisation)

$$P(X_1) = \sum_{\{X\} \setminus X_1} P(X_1, X_2, \dots, X_N)$$

- Notez : pour obtenir une probabilité conditionnelle on peut utiliser le concept de conditionnement
« **conditioning** »

$$P(A | B) = \frac{P(A, B)}{P(B)}$$

Probabilités – notions de base

- Théorème de Bayes avec évidence (**e**), des observations, ou certaines variables observées:

$$P(X|Y) = \frac{P(Y|X) P(X)}{P(Y)}$$

$$P(X|Y, \mathbf{e}) = \frac{P(Y|X, \mathbf{e}) P(X|\mathbf{e})}{P(Y|\mathbf{e})}$$

Probabilités – notions de base

- *Indépendance*: deux variables X et Y sont indépendantes si $P(X,Y) = P(X)P(Y)$ ou encore si $P(X|Y) = P(X)$ et $P(Y|X) = P(Y)$
- *Indépendance conditionnelle*:
 - $P(X,Y|A) = P(X|A)P(Y|A)$
 - ou encore: $P(X|Y, A) = P(X|A)$ et $P(Y|X, A) = P(Y|A)$

Définition: Un réseau de Bayes

- Il représente une factorisation d'une probabilité jointe des variables V_i de la forme:


$$P(V_1, V_2, \dots, V_n) = \prod_{i=1}^n P(V_i \mid \text{parents}(V_i))$$

si $\text{parents}(V_i) = \emptyset$ (il n'a pas de parents)


alors, $P(V_i \mid \emptyset) = P(V_i)$

- Pour écrire le réseau: il y a un nœud (cercle) pour chaque variable et une arête orienté entre chaque variable et ses parents.
- Nœud gris implique que la variable est observée avec évidence (exact / dur, ou incertain / douce)

Exemples des modèles où A et C sont conditionnellement indépendants sachant B




Influence pipelinée




Influence divergente

Exemples d'un modèle où **A** et **C** sont conditionnellement dépendants sachant **B**

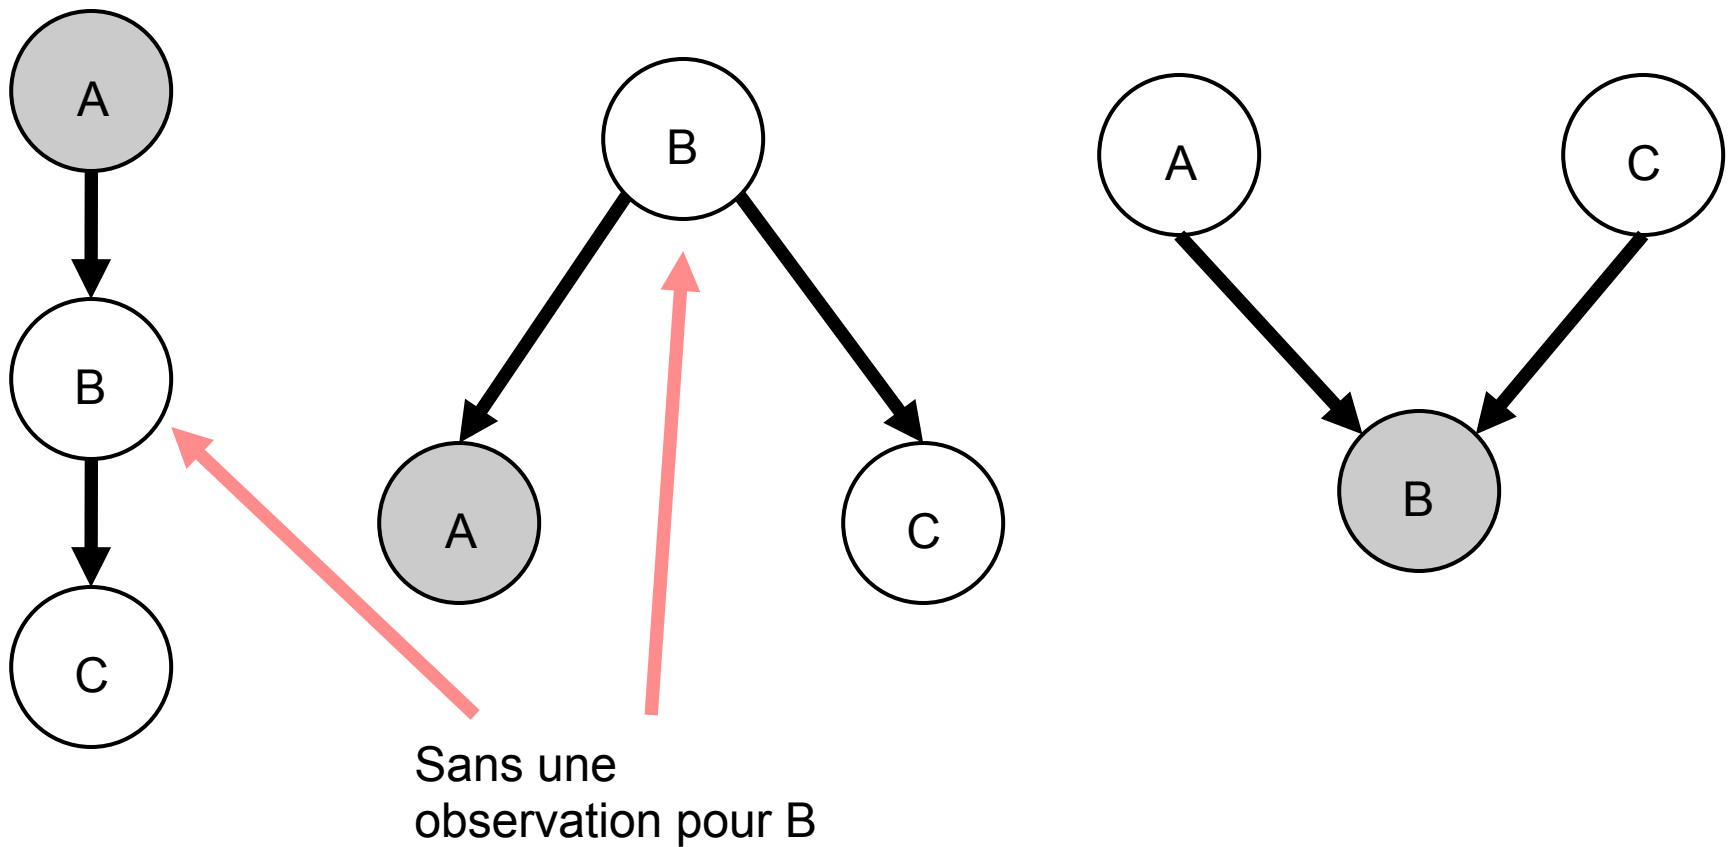


Influence convergente

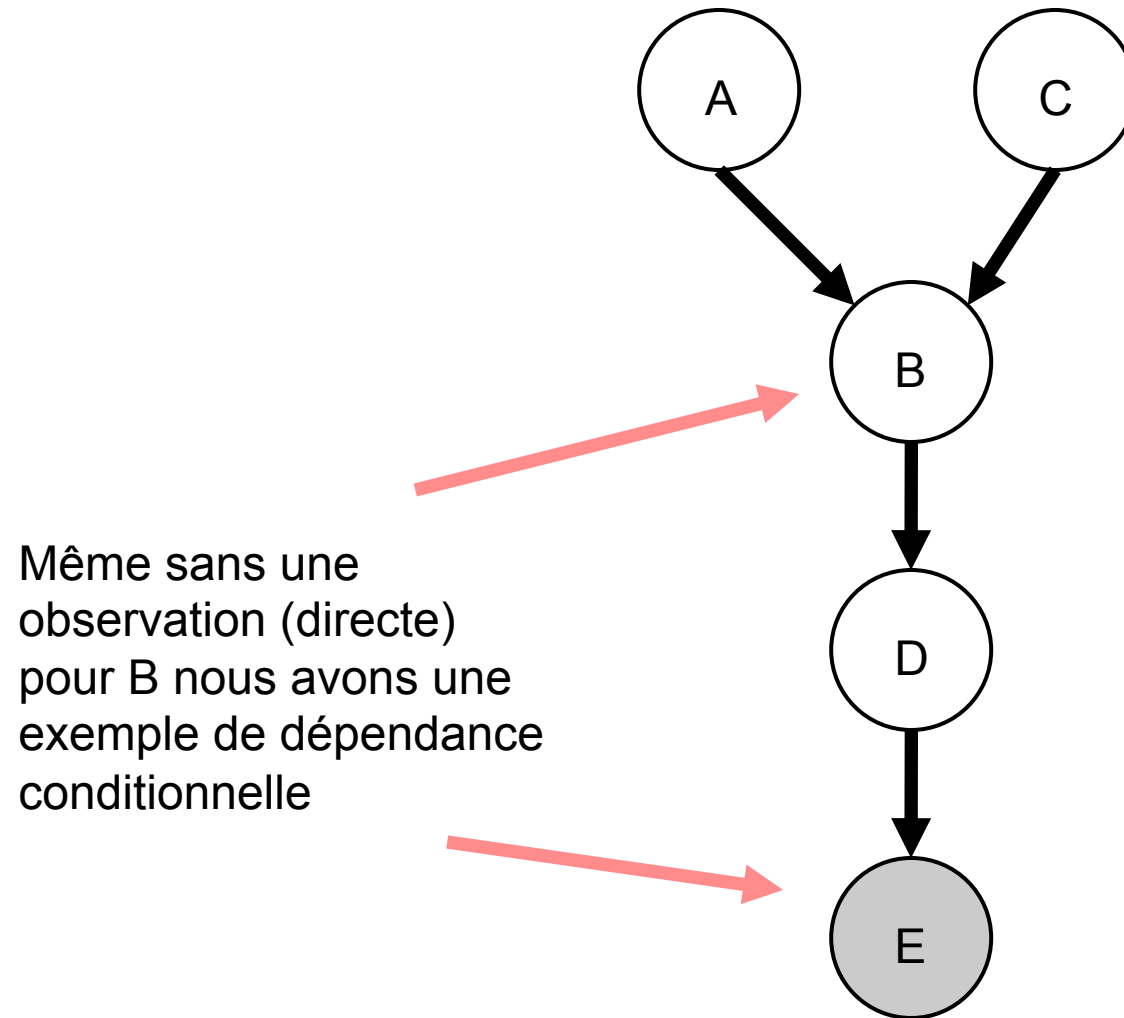
**Par contre, sans évidence A et C
sont indépendantes**



Exemples ou A et C sont dépendants



Exemple ou A et C sont dépendants




Exemple - Modélisation

Considérons la modélisation suivant d'un problème simple

$P(\text{Détecte}, \text{Douleur}, \text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur}, \text{Carie}, \text{Compétent})$




Idée importante : Il est possible d'appliquer nos règles simples récursivement avec les groupes de variables.

Exemple (suite) - Modélisation

$P(\text{Détecte}, \text{Douleur}, \text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur}, \text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie}, \text{Compétent})$



Exemple (suite)

$P(\text{Détecte}, \text{Douleur}, \text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur}, \text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie} | \text{Compétent}) \times P(\text{Compétent})$

Possible, mais...

Exemple (suite)

$P(\text{Détecte}, \text{Douleur}, \text{Carie}, \text{Compétent})$

$$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie} | \text{Compétent}) \times P(\text{Compétent})$$

$$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie}) \times P(\text{Compétent})$$

La présence de carie ne dépend pas de la compétence du dentiste

Exemple (suite)

$P(\text{Détecte}, \text{Douleur}, \text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie} | \text{Compétent}) \times P(\text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie}) \times P(\text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}) \times P(\text{Carie}) \times P(\text{Compétent})$

La présence de douleur ne dépend pas de la compétence du dentiste

Exemple (suite)

$P(\text{Détecte}, \text{Douleur}, \text{Carie}, \text{Compétent})$

$= P(\text{Détecte} | \text{Douleur}, \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie} | \text{Compétent}) \times P(\text{Compétent})$


$= P(\text{Détecte} | \text{~~Douleur~~, Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}, \text{Compétent}) \times P(\text{Carie}) \times P(\text{Compétent})$

$= P(\text{Détecte} | \text{Carie}, \text{Compétent}) \times P(\text{Douleur} | \text{Carie}) \times P(\text{Carie}) \times P(\text{Compétent})$

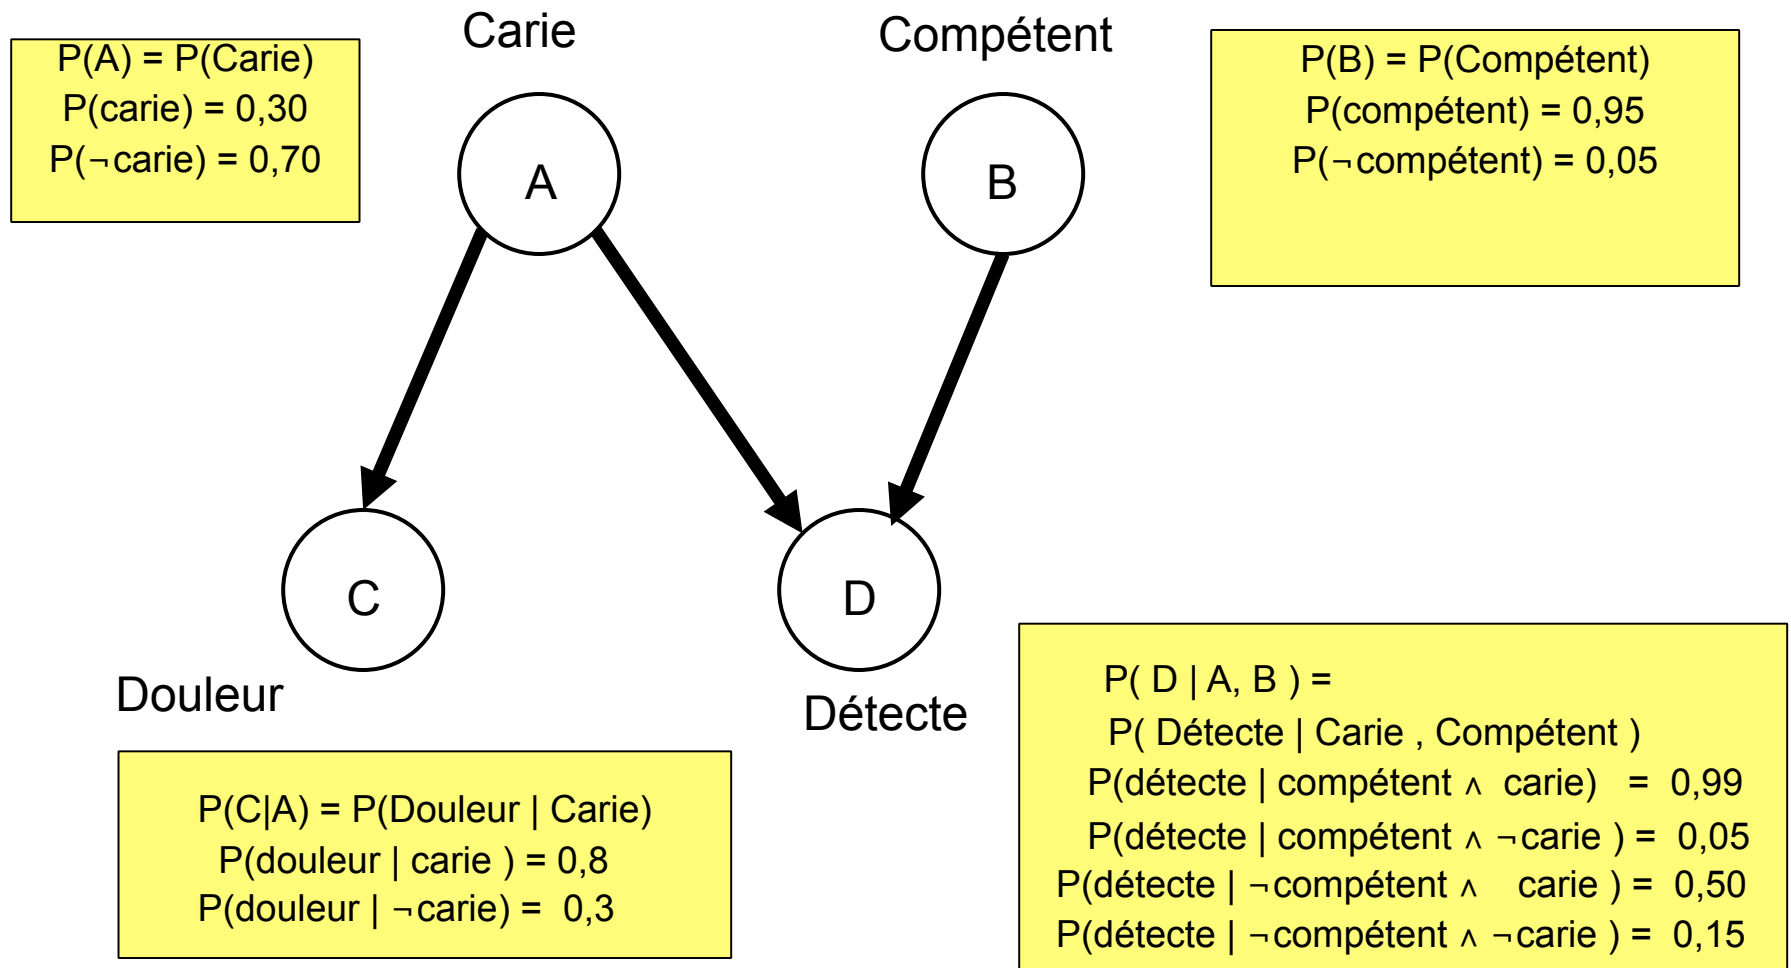
La détection d'une anomalie ne dépend pas de la présence de douleur

Exemple (suite)

On obtient donc un réseau de Bayes avec la structure suivante :



Exemple (suite)




Notre exemple (suite)

- Distribution jointe complète:

| | |
|--|----------|
| [detecte===0, douleur===0, competent===0, carie===0] | 0.020825 |
| [detecte===1, douleur===0, competent===0, carie===0] | 0.003675 |
| [detecte===0, douleur===1, competent===0, carie===0] | 0.008925 |
| [detecte===1, douleur===1, competent===0, carie===0] | 0.001575 |
| [detecte===0, douleur===0, competent===1, carie===0] | 0.442225 |
| [detecte===1, douleur===0, competent===1, carie===0] | 0.023275 |
| [detecte===0, douleur===1, competent===1, carie===0] | 0.189525 |
| [detecte===1, douleur===1, competent===1, carie===0] | 0.009975 |
| [detecte===0, douleur===0, competent===0, carie===1] | 0.0015 |
| [detecte===1, douleur===0, competent===0, carie===1] | 0.0015 |
| [detecte===0, douleur===1, competent===0, carie===1] | 0.006 |
| [detecte===1, douleur===1, competent===0, carie===1] | 0.006 |
| [detecte===0, douleur===0, competent===1, carie===1] | 0.00057 |
| [detecte===1, douleur===0, competent===1, carie===1] | 0.05643 |
| [detecte===0, douleur===1, competent===1, carie===1] | 0.00228 |
| [detecte===1, douleur===1, competent===1, carie===1] | 0.22572 |

Autre exemple avec le même structure (exemple célèbre de « wetgrass »)

On obtient donc un réseau de Bayes avec la structure suivante :



Exemple : « Explaining Away »

Pour un même jeu de données...

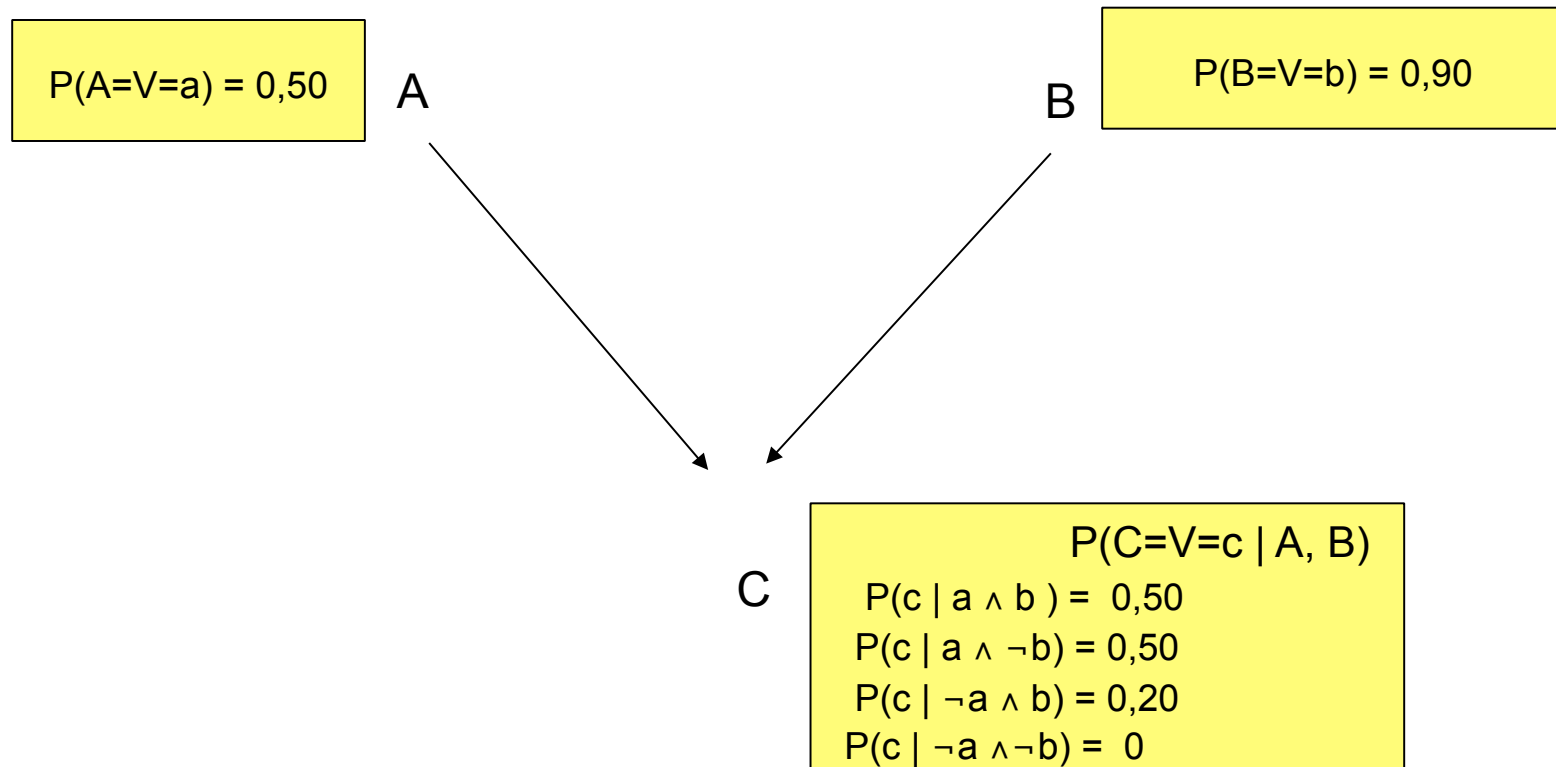
Plusieurs réseaux possibles

Exemple : Etant donné la distribution jointe complète pour les variables binaires A, B et C,

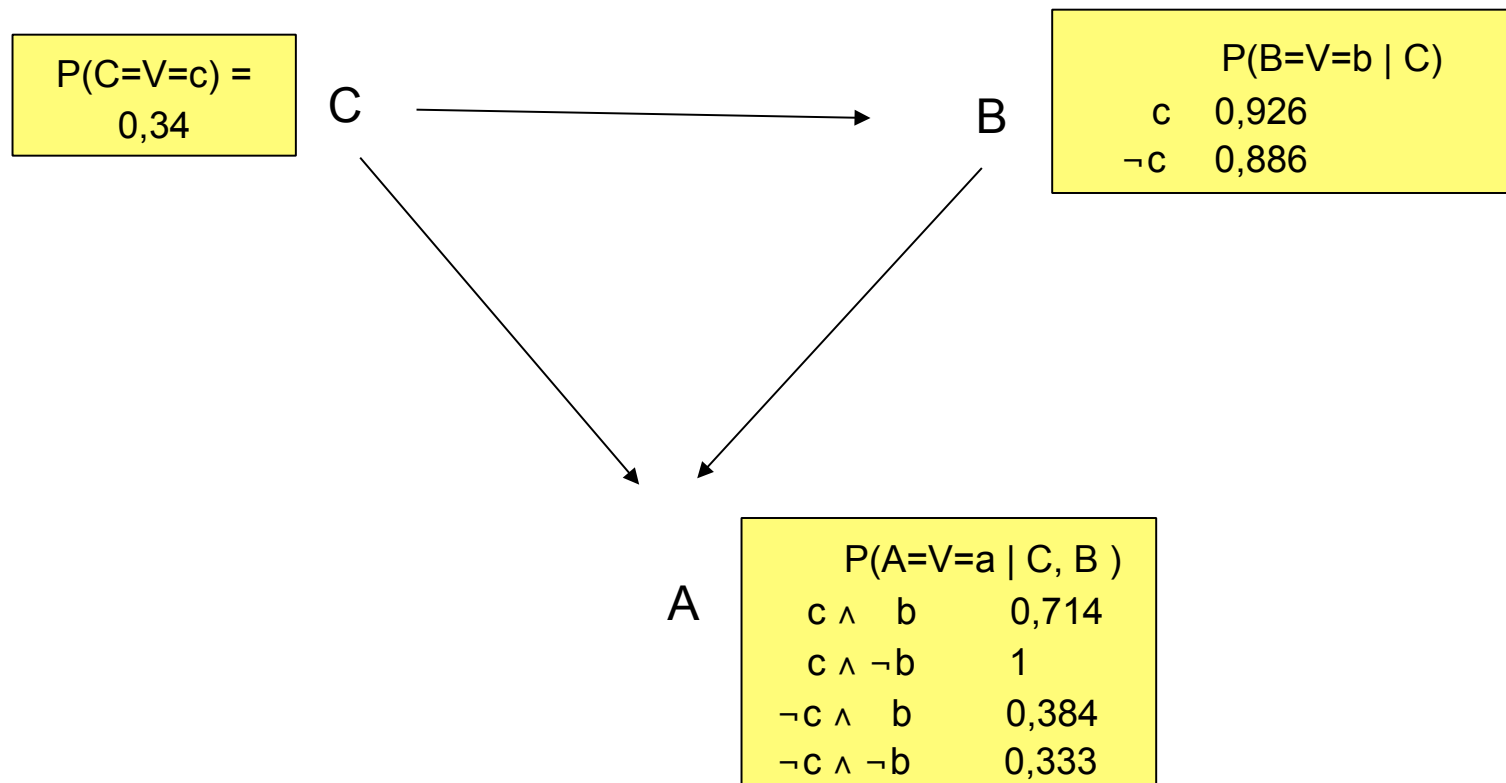
Rapel – notation : $A = \text{Vrai} = V = a$, $A = \text{Faux} = F = \neg a$

| | |
|--------------------------------------|-------|
| $a \wedge b \wedge c$ | 0.225 |
| $a \wedge b \wedge \neg c$ | 0.225 |
| $a \wedge \neg b \wedge c$ | 0.025 |
| $a \wedge \neg b \wedge \neg c$ | 0.025 |
| $\neg a \wedge b \wedge c$ | 0.09 |
| $\neg a \wedge b \wedge \neg c$ | 0.36 |
| $\neg a \wedge \neg b \wedge c$ | 0 |
| $\neg a \wedge \neg b \wedge \neg c$ | 0.05 |

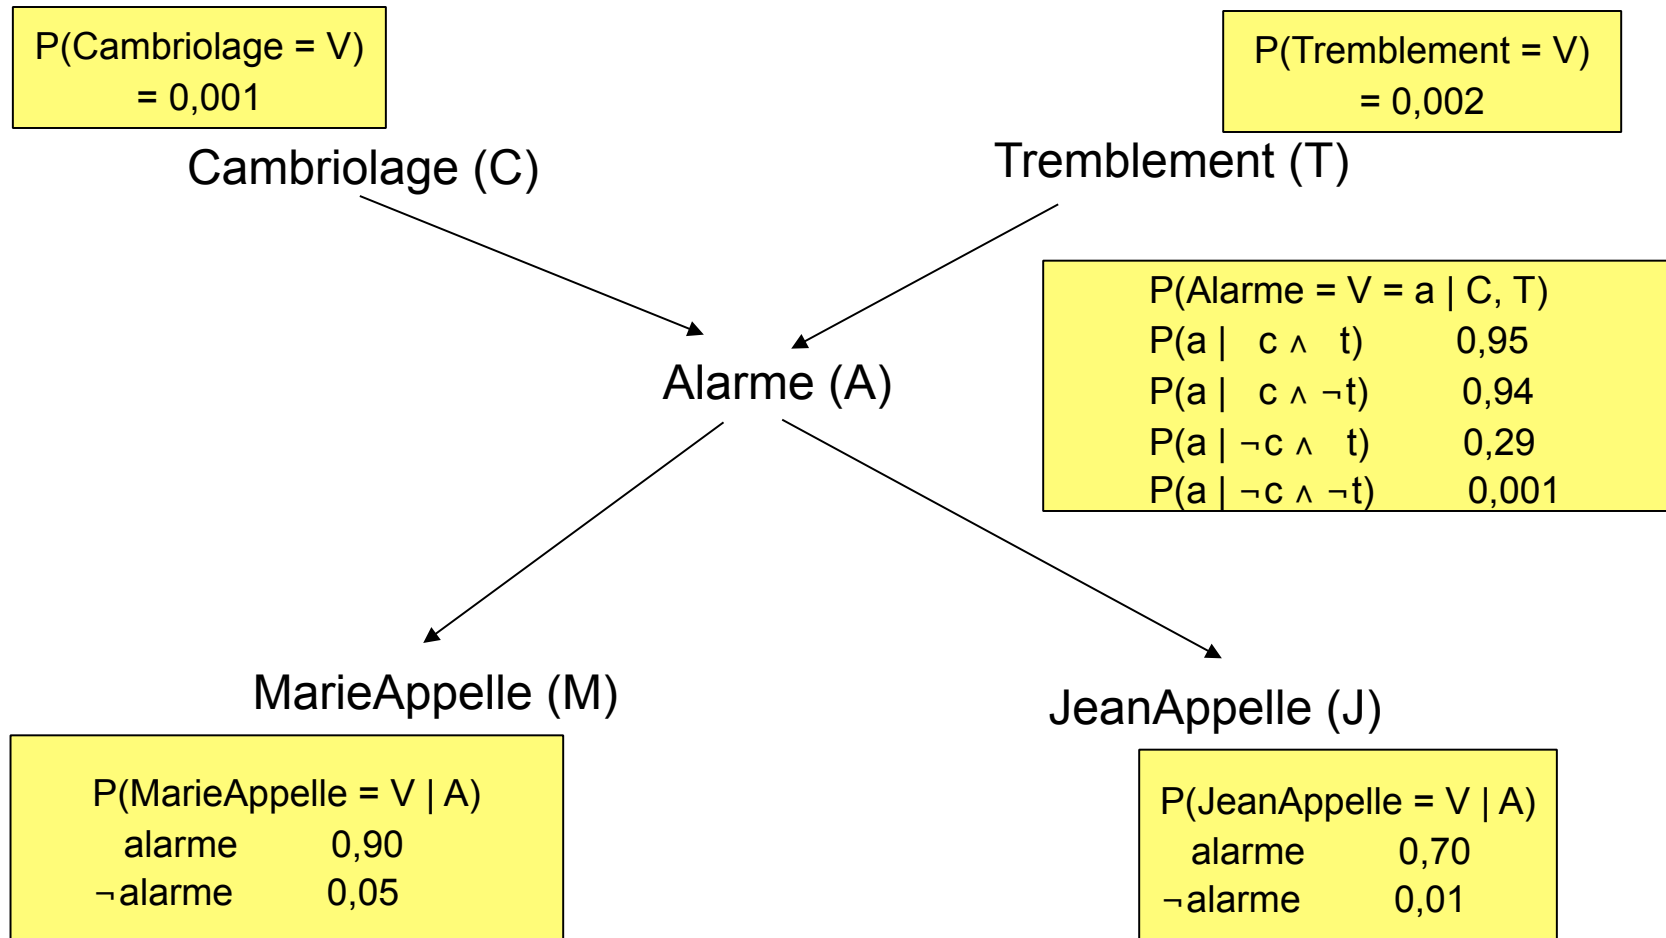
Plusieurs réseaux possibles pour un même jeu de données




Plusieurs réseaux possibles...



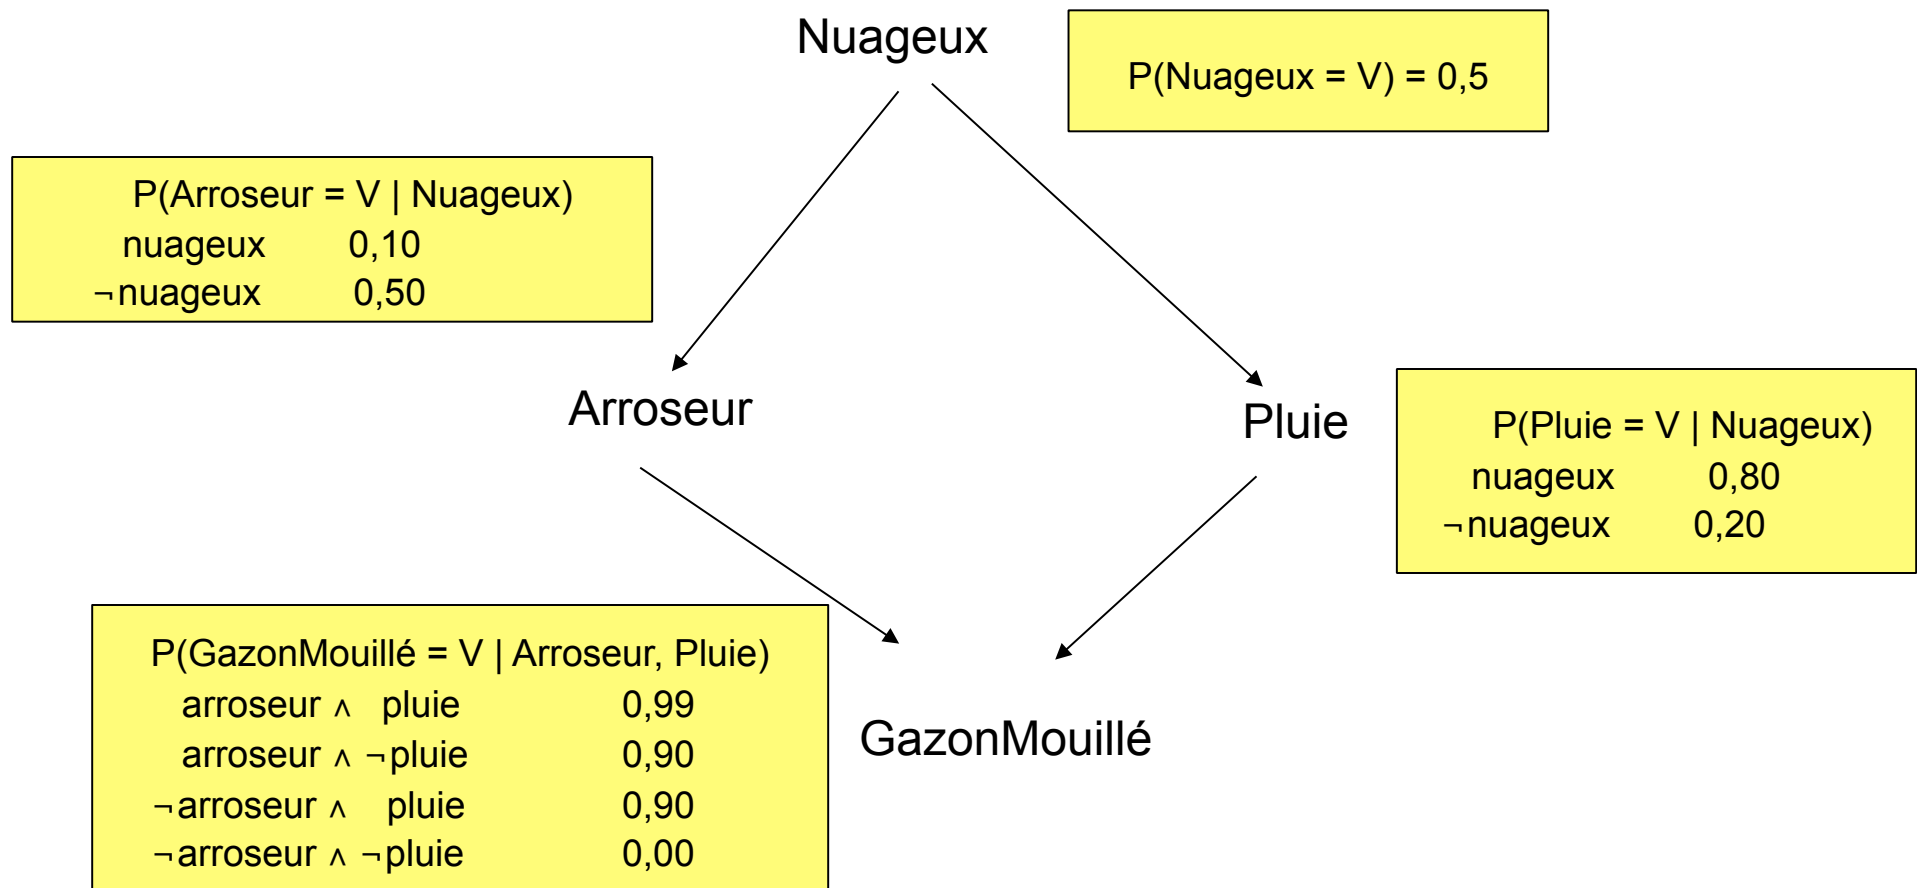
Exemple (célèbre) « earthquake »



Exemple



Exemple




Indépendance conditionnelle dans les réseaux bayésiens


- Un noeud est conditionnellement indépendant de ses non-descendants, étant donné ses parents
- Un noeud est conditionnellement indépendant de tous les autres noeuds du réseau, étant donné sa couverture de Markov (c'est-à-dire ses parents, ses enfants et les parents de ses enfants)

Couverture de Markov


- Etant donné un nœud, la couverture de Markov consiste de ses parents, ses enfants et les autres parents de ses enfants.




Exemple – indép. conditionnelle






Exemple – indép. conditionnelle







Exemple – indép. conditionnelle




Les noeuds  sont indépendants du noeud  étant donné le noeud 




Exemple – indép. conditionnelle




Les noeuds  sont indépendants du noeud  étant donné le noeud 

Exemple – indép. conditionnelle




Les noeuds  sont indépendants du noeud  étant donné le noeud 

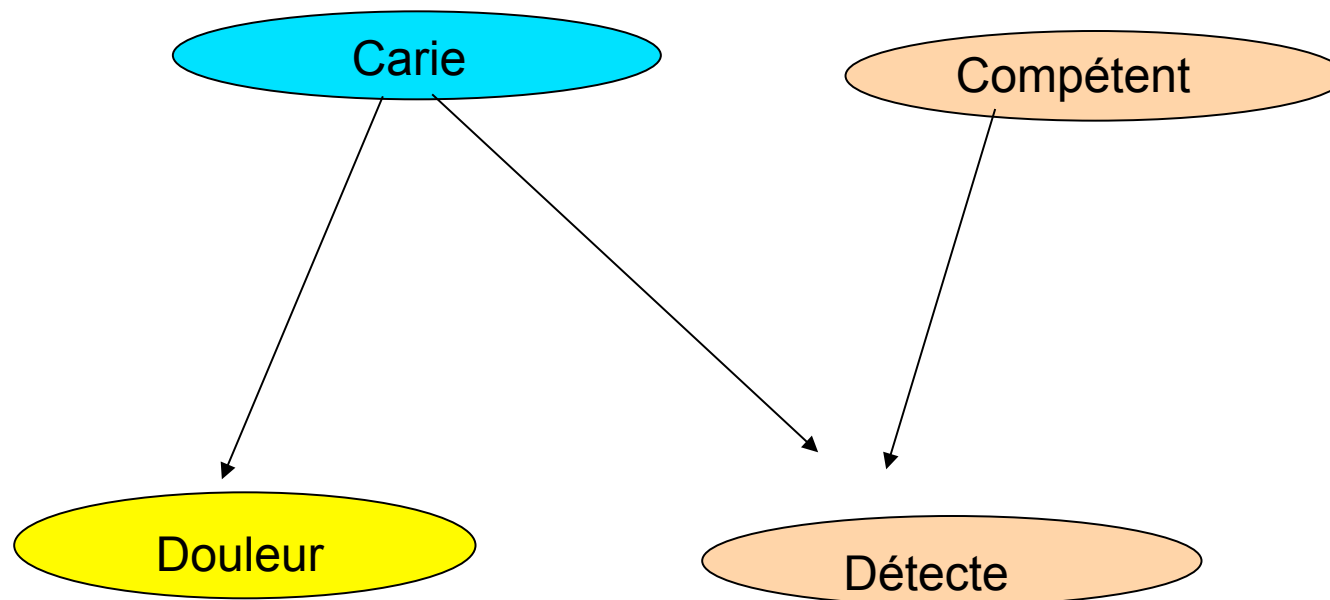
Exemple – indép. conditionnelle






Exemple – indép. conditionnelle

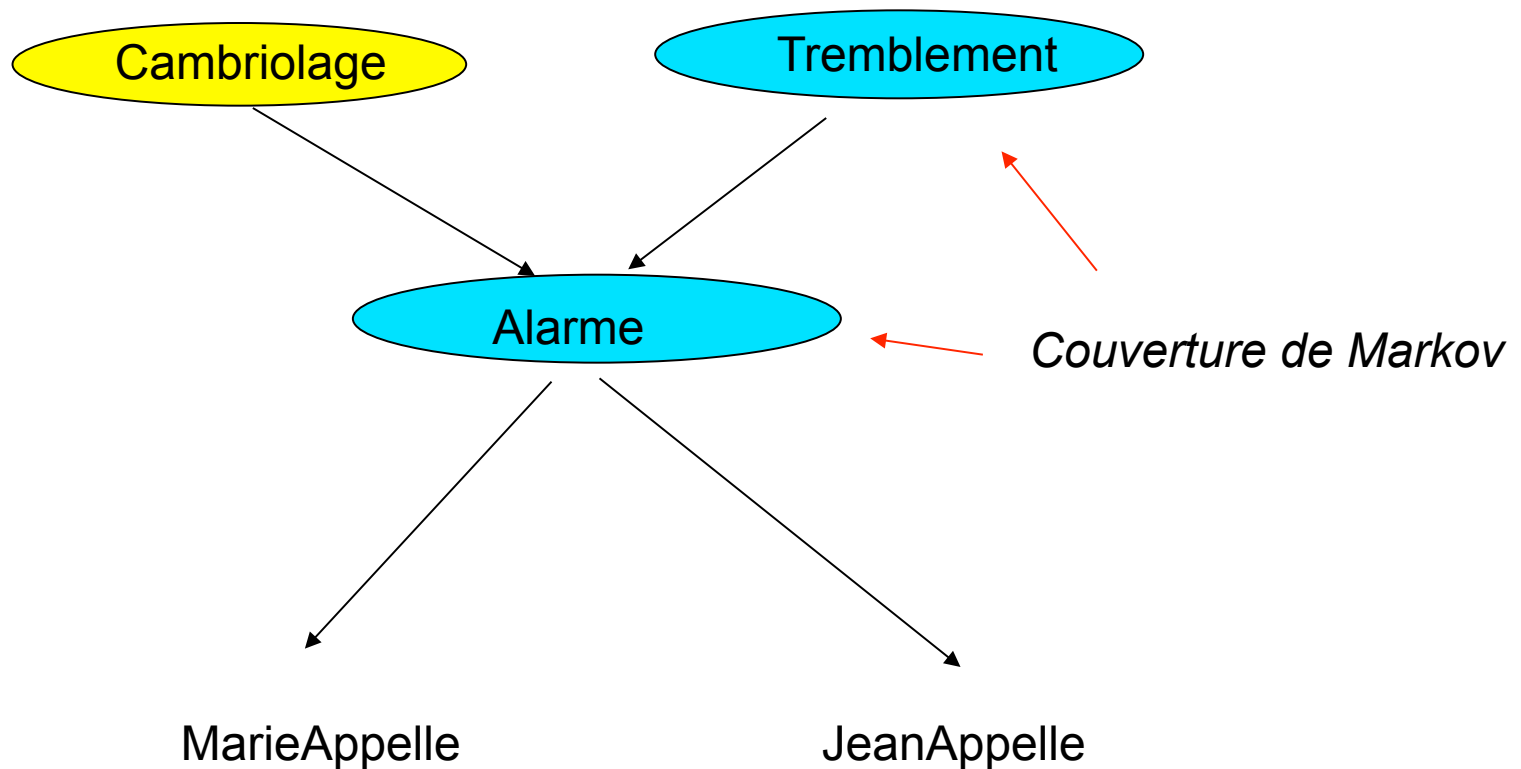


Exemple – indép. conditionnelle

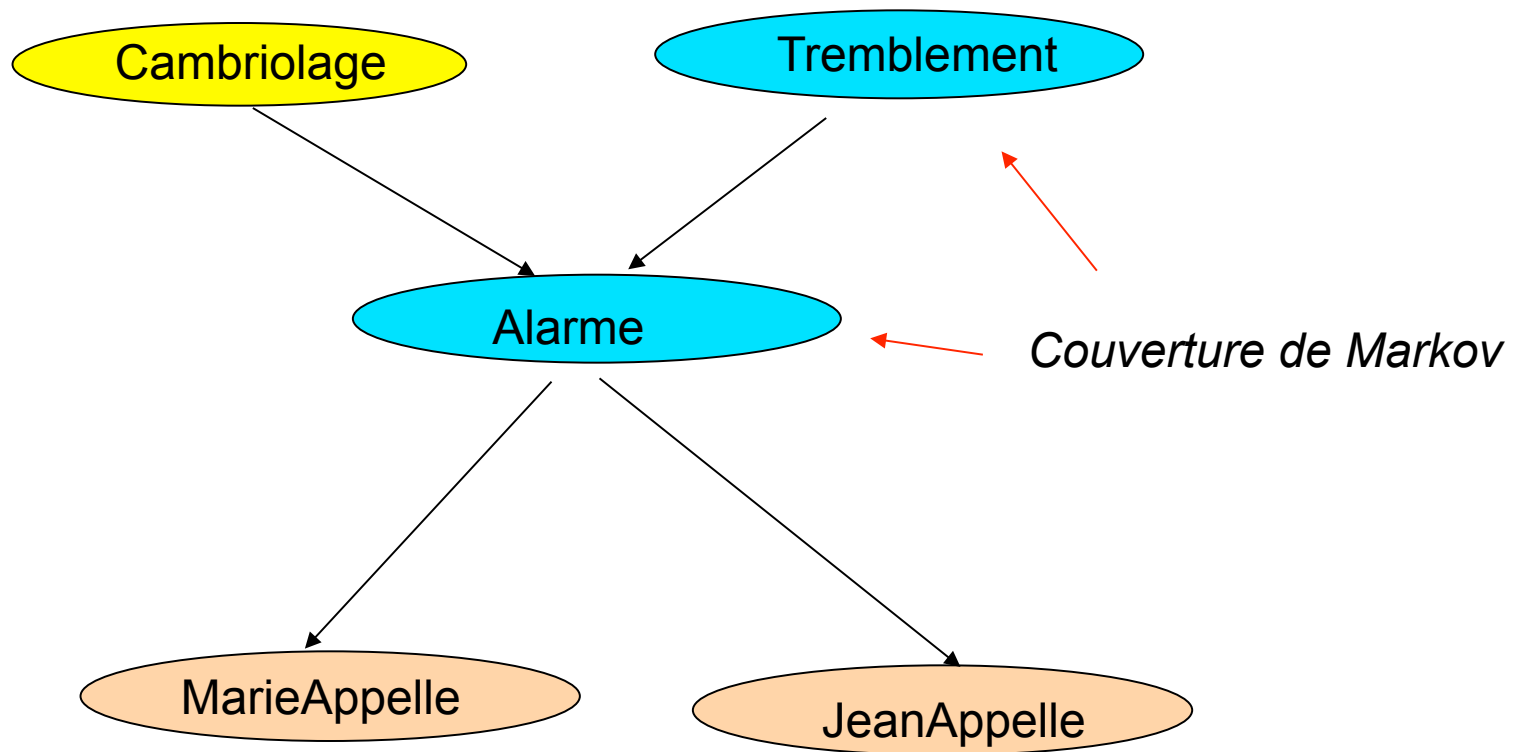


Les noeuds  sont indépendants du noeud  étant donné le noeud 

Exemple – indép. conditionnelle



Exemple – indép. conditionnelle



Les noeuds [orange oval] sont indépendants du noeud [yellow oval] étant donné le noeud [cyan oval]


Calcul des probabilités

- Technique du OU bruité
- On calcule individuellement la probabilité d'une des causes
- On suppose
 - que toutes les causes sont connues
 - que l'inhibition d'une cause est indépendante de celle des autres causes

Considérons

La marginalisation
nécessaire pour calculer :

$$P(X_4 = x_4)$$



$$= \sum_{x_1} \sum_{x_2} \sum_{x_3} P(X_1 = x_1, X_2 = x_2, X_3 = x_3, X_4 = x_4)$$

$$= \sum_{x_1} \sum_{x_2} \sum_{x_3} P(X_1 = x_1) P(X_2 = x_2) P(X_3 = x_3 | X_1 = x_1)$$

$$P(X_4 = x_4 | X_1 = x_1, X_2 = x_2)$$

Exercice : Combien multiplications et additions avec des variables binaires?

Inférence exacte

- On calcule les probabilités en utilisant directement la formule, en sommant sur les variables cachées
- Si le réseau est un poly-arbre, le temps est proportionnel à la taille du réseau
- Puisque la logique propositionnelle est un cas particulier des réseaux bayésiens, l'inférence est donc NP-difficile de manière générale


Considérons

$$f_1(x_1) = P(X_1 = x_1)$$

$$f_2(x_2) = P(X_2 = x_2)$$

$$f_3(x_1, x_3) = P(X_3 = x_3 | X_1 = x_1)$$

$$f_4(x_1, x_2, x_4) = P(X_4 = x_4 | X_1 = x_1, X_2 = x_2)$$



$$P(X_4 = x_4) =$$

$$= \sum_{x_1} \sum_{x_2} \sum_{x_3} f_1(x_1) f_2(x_2) f_3(x_1, x_3) f_4(x_1, x_2, x_4)$$

$$= \sum_{x_1} f_1(x_1) \sum_{x_3} f_3(x_1, x_3) \underbrace{\sum_{x_2} f_2(x_2) f_4(x_1, x_2, x_4)}_{g_2(x_1, x_4)}$$

$$= \sum_{x_1} f_1(x_1) \left(\sum_{x_2} f_2(x_2) f_4(x_1, x_2, x_4) \right) \sum_{x_3} f_3(x_1, x_3)$$

Exercice : Combien multiplications et additions avec des variables binaires?

Idée fondamentale : Factor Graphs

Kschischang, Frank R.; Brendan J. Frey and Hans-Andrea Loeliger (2001), "Factor Graphs and the Sum-Product Algorithm", *IEEE Transactions on Information Theory* 47 (2): pp. 498–519.

Définition: Un graphe de facteurs

- Il est possible de créer une fonction à partir des produits de s fonctions f_i de sous-ensembles de variables $\{X\}_i$

$$F(X_1, X_2, \dots, X_n) = \prod_{i=1}^s f_i(\{X\}_i)$$

- Exemple : notre modèle recent, où nous avons


$$\begin{aligned} P(A, B, C, D) &= f_1(\{X\}_1) f_2(\{X\}_2) f_3(\{X\}_3) f_4(\{X\}_4) \\ &= P(C \mid A) P(D \mid A, B) P(A) P(B) \end{aligned}$$

Un graphe de facteurs

Il se compose de (simplement) des :

- Rectangles pour chaque fonction, et des
- Liens, sans orientation entre chaque fonction et chaque variable dans la fonction


Considérons



Exercice : Ecrivez un graphe de facteurs.

Exercice :

Écrivez un graphe de facteurs.



$$f_1(C, A) = P(C \mid A)$$

$$f_2(D, A, B) = P(D \mid A, B)$$



$$f_3(A) = P(A)$$

$$f_4(B) = P(B)$$

Il se compose de :

- Rectangles pour chaque fonction
- Liens, sans orientation entre la fonction et chaque variable dans la fonction

Un graphe de facteurs



Un autre exemple

► *Example 1 (A Simple Factor Graph):* Let $g(x_1, x_2, x_3, x_4, x_5)$ be a function of five variables, and suppose that g can be expressed as a product

$$g(x_1, x_2, x_3, x_4, x_5) = f_A(x_1)f_B(x_2)f_C(x_1, x_2, x_3)f_D(x_3, x_4)f_E(x_3, x_5) \quad (2)$$




Fig. 1. A factor graph for the product $f_A(x_1)f_B(x_2)f_C(x_1, x_2, x_3) \cdot f_D(x_3, x_4)f_E(x_3, x_5)$.

Une méthode de calculer des probabilités par le passage de messages

- Les messages sont des vecteurs de nombres réels
- Les messages sont transmis de noeuds variables à des noeuds fonction, et de noeuds fonction à noeuds variables
- Un noeud peut envoyer un message à son voisin seulement si elle a reçu tous les messages de ses autres voisins.
- Étant donné un arbre, l'algorithme peut commencer par envoyant des messages de chaque des feuilles, et s'arrête une fois que chaque noeud a transmis un message à tous voisin.

Les messages fonction à variable

- Les messages entre une fonction f et une variable X sont calculé par

$$m_{f \rightarrow X}(x) = \sum_{x_1, \dots, x_k} f(x, x_1, \dots, x_k) m_{X_1 \rightarrow f}(x_1) \cdots m_{X_k \rightarrow f}(x_k)$$

- Avec une somme sur toutes les autres variables X_1, \dots, X_k (sauf X) avec un arc à f et sur le produit de la fonction et tous les messages variable-fonction à partir de ces autres variables
- Si f contient seulement X , alors $m_{f \rightarrow X}(x) = f(x)$.
(on a un nœud fonction feuille)

Les messages variable-fonction

- Les messages entre une variable X et une fonction f sont calculé par

$$m_{X \rightarrow f}(x) = \begin{cases} 1 & , \text{noeud (variable) feuille} \\ m_{f_1 \rightarrow X}(x) \cdots m_{f_k \rightarrow X}(x) & \text{autrement} \end{cases}$$

- Ou simplement un produit sur toutes les messages d'autres fonctions f_1, \dots, f_k (sauf f) contenant X

À la fin

- Une fois que tous les messages ont été transmis,
- alors le marginal final pour toute variable X peut être calculé par

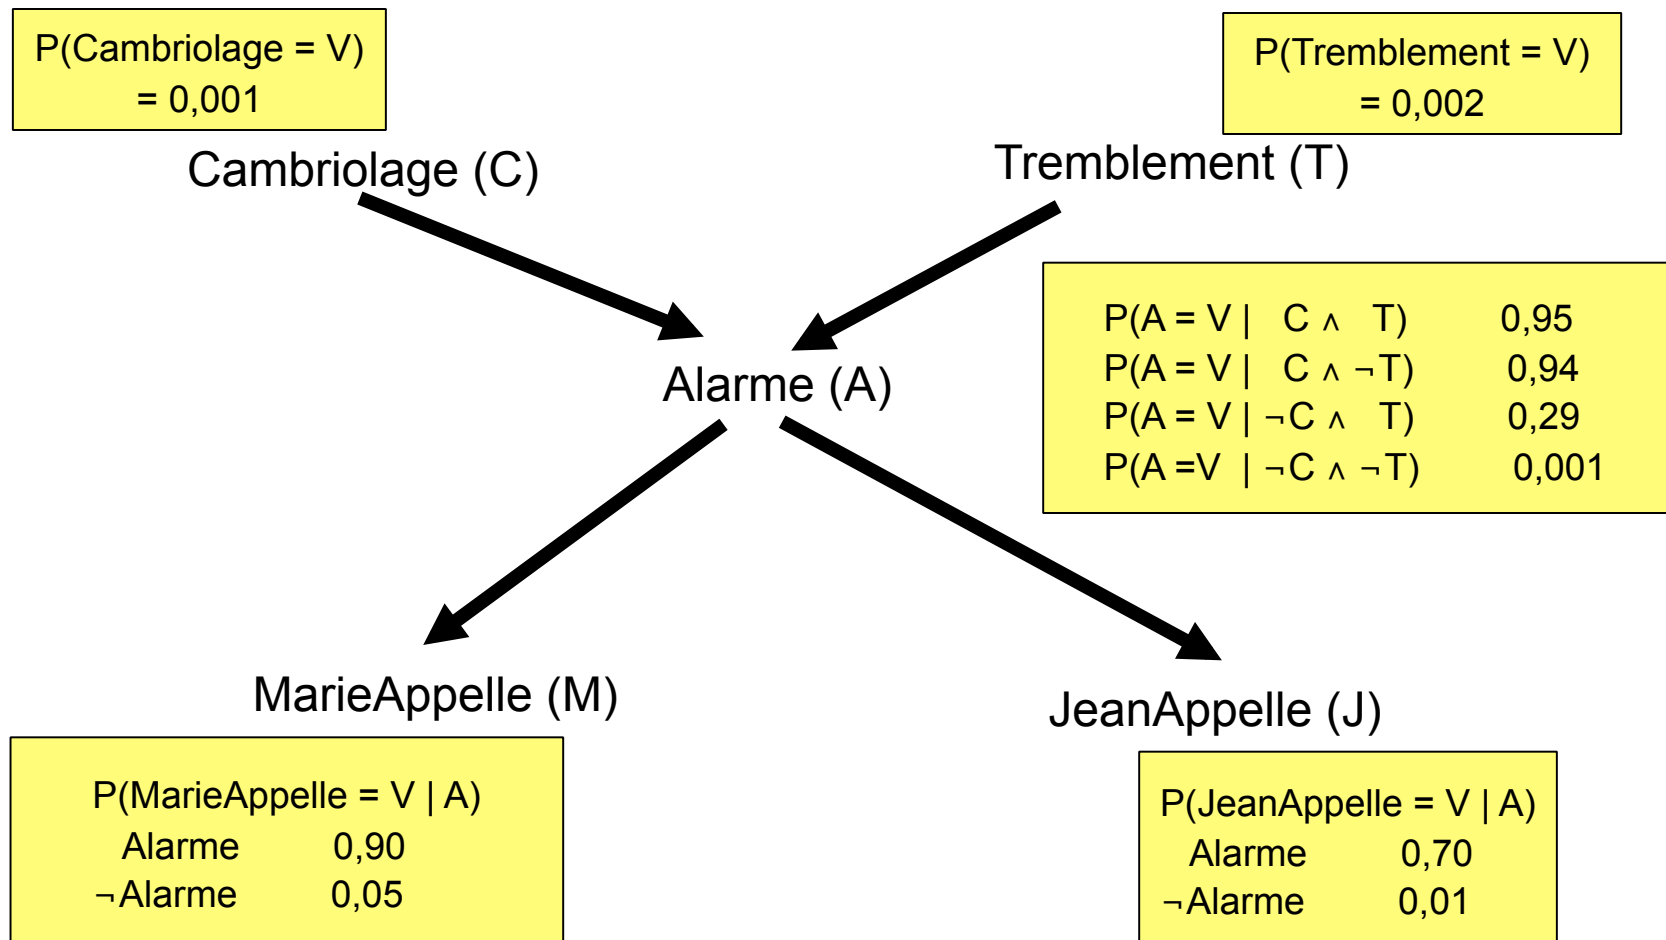
$$P(X_i = x_i) = m_{f_1 \rightarrow X_i}(x_i) \cdots m_{f_k \rightarrow X_i}(x_i)$$

- sur toutes les fonctions f_1, \dots, f_k contenant X


Exemple concrète


Des graphes de facteurs et
l'algorithme somme - produit

Exemple : Le réseau « Alarme »



Un exemple de passage de message, ou un méthode pour « compiler » le réseau (dans le sens d'un logiciel comme Netica)






Step 1:

$$\mu_{f_A \rightarrow x_1}(x_1) = \sum_{\sim\{x_1\}} f_A(x_1) = f_A(x_1)$$

$$\mu_{f_B \rightarrow x_2}(x_2) = \sum_{\sim\{x_2\}} f_B(x_2) = f_B(x_2)$$

$$\mu_{x_4 \rightarrow f_D}(x_4) = 1$$

$$\mu_{x_5 \rightarrow f_E}(x_5) = 1.$$




Step 2:

$$\mu_{x_1 \rightarrow f_C}(x_1) = \mu_{f_A \rightarrow x_1}(x_1)$$

$$\mu_{x_2 \rightarrow f_C}(x_2) = \mu_{f_B \rightarrow x_2}(x_2)$$

$$\mu_{f_D \rightarrow x_3}(x_3) = \sum_{\sim \{x_3\}} \mu_{x_4 \rightarrow f_D}(x_4) f_D(x_3, x_4)$$

$$\mu_{f_E \rightarrow x_3}(x_3) = \sum_{\sim \{x_3\}} \mu_{x_5 \rightarrow f_E}(x_5) f_E(x_3, x_5).$$



Step 3:

$$\mu_{f_C \rightarrow x_3}(x_3) = \sum_{\sim\{x_3\}} \mu_{x_1 \rightarrow f_C}(x_1) \mu_{x_2 \rightarrow f_C}(x_2) f_C(x_1, x_2, x_3)$$

$$\mu_{x_3 \rightarrow f_C}(x_3) = \mu_{f_D \rightarrow x_3}(x_3) \mu_{f_E \rightarrow x_3}(x_3).$$


Step 4:

$$\mu_{f_C \rightarrow x_1}(x_1) = \sum_{\sim\{x_1\}} \mu_{x_3 \rightarrow f_C}(x_3) \mu_{x_2 \rightarrow f_C}(x_2) f_C(x_1, x_2, x_3)$$

$$\mu_{f_C \rightarrow x_2}(x_2) = \sum_{\sim\{x_2\}} \mu_{x_3 \rightarrow f_C}(x_3) \mu_{x_1 \rightarrow f_C}(x_1) f_C(x_1, x_2, x_3)$$

$$\mu_{x_3 \rightarrow f_D}(x_3) = \mu_{f_C \rightarrow x_3}(x_3) \mu_{f_E \rightarrow x_3}(x_3)$$

$$\mu_{x_3 \rightarrow f_E}(x_3) = \mu_{f_C \rightarrow x_3}(x_3) \mu_{f_D \rightarrow x_3}(x_3).$$




Step 5:

$$\mu_{x_1 \rightarrow f_A}(x_1) = \mu_{f_C \rightarrow x_1}(x_1)$$

$$\mu_{x_2 \rightarrow f_B}(x_2) = \mu_{f_C \rightarrow x_2}(x_2)$$

$$\mu_{f_D \rightarrow x_4}(x_4) = \sum_{\sim\{x_4\}} \mu_{x_3 \rightarrow f_D}(x_3) f_D(x_3, x_4)$$

$$\mu_{f_E \rightarrow x_5}(x_5) = \sum_{\sim\{x_5\}} \mu_{x_3 \rightarrow f_E}(x_3) f_E(x_3, x_5).$$



Termination:

$$g_1(x_1) = \mu_{f_A \rightarrow x_1}(x_1) \mu_{f_C \rightarrow x_1}(x_1)$$

$$g_2(x_2) = \mu_{f_B \rightarrow x_2}(x_2) \mu_{f_C \rightarrow x_2}(x_2)$$

$$g_3(x_3) = \mu_{f_C \rightarrow x_3}(x_3) \mu_{f_D \rightarrow x_3}(x_3) \mu_{f_E \rightarrow x_3}(x_3)$$

$$g_4(x_4) = \mu_{f_D \rightarrow x_4}(x_4)$$

$$g_5(x_5) = \mu_{f_E \rightarrow x_5}(x_5).$$

Probabilités marginales et l'algorithme de somme-produit

- Dans les graphes avec quelques observations inconnues (ou des variables cachées) nous avons besoin de distributions marginales.
- Pour apprentissage avec des variables inconnues, les algorithmes tels que la maximisation d'espérance (EM) sont typiquement utilisées pour estimer des paramètres
- Ces algorithmes exigeant de nous de calculer des distributions marginales locales
- Donc, dans beaucoup de circonstances importantes on a besoin de marginales

Inférence exacte vs. approximative

- Pour les graphes de facteurs à structure arborescente, nous pouvons calculer toutes les probabilités marginales sans approximation avec l'algorithme de somme-produit (défini avec des graphes de facteurs)
- On parle souvent d'inférence exacte dans un arbre
- Quand il existe un ou plusieurs cycles dans un graphe de facteurs, il est possible d'appliquer l'algorithme de somme-produit, toutefois l'inférence sera une approximation

Calculant la « meilleure configuration » et l'algorithme maximum - produit

- Un marginal est une distribution locale de probabilité dans un graphique après avoir intégré sur d'autres variables
- La meilleure configuration d'un graphe est les meilleures valeurs des variables
- Pour un modèle de probabilité, c'est l'explication la plus probable (l'EPP ou MPE en anglais)
- Pour un réseau bayésien ou un modèle avec une distribution a priori, une vraisemblance et un postérieur, nous référons souvent à la tâche d'inférence maximum a posteriori (MAP) pour : a) des variables aléatoires ou b) pour l'estimation des paramètres en utilisant une probabilité a priori